ACTIVIDAD 6

Asistente de preparación de revisiones de portafolio
Evaluación y validación de modelos de clasificación



Vértice AI Consulting · Convertimos datos en decisiones

Materia:	*Gestión de Proyectos de Inteligencia Artificial*
Actividad:	Actividad 6 · Módulo 2 / Semana 7 · Temas 13 y 14
Alumno(a):	*Eduardo Aburto Angulo*
Matrícula:	*AL07182743*
Docente:	*M. en C. Luis Ariel Vázquez Piña*
Fecha de entrega:	22 - 10 - 2026

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	Sí	ChatGPT/Codex apoyó la programación, ejecución, verificación y elaboración de esta entrega. Las métricas provienen de ejecuciones registradas. La prueba A/B utiliza resultados simulados y se identifica como tal.
Claude (Anthropic)	Antecedentes	Uso declarado en entregas previas; no se atribuyen nuevas ejecuciones a esta herramienta.
Gemini (Google)	Antecedentes	Uso declarado en entregas previas; no se atribuyen nuevas ejecuciones a esta herramienta.
Copilot (Microsoft)	Antecedentes	Uso declarado en entregas previas; no se atribuyen nuevas ejecuciones a esta herramienta.
Otra (especifica):	Antecedentes	Uso declarado en entregas previas; no se atribuyen nuevas ejecuciones a esta herramienta.

Desarrollo de Contenido

Decisión y objetivo de evaluación

Mi prioridad como Banquero Patrimonial Sr. es preparar revisiones que protejan el perfil de inversión y busquen mejores rendimientos netos para el cliente. Seleccioné una SVM calibrada como candidata de investigación para detectar noticias financieras negativas. Con un umbral de 0.20 recupera 51 de 61 noticias negativas del test histórico. Aun así, no alcanza el recall de 90 % que fijé como meta; por eso no propongo automatizar movimientos ni iniciar un despliegue operativo.

El asistente organiza señales para revisión humana. Una noticia negativa no demuestra que un fondo vaya a caer, ni justifica por sí sola venderlo. Antes de cualquier migración se necesita vincular la noticia con exposiciones reales, contrastar fuentes, revisar horizonte, liquidez, perfil y costos. Esta actividad evalúa el primer componente de ese proceso, no una estrategia de inversión.

Objetivo SMART al cierre del 22 de octubre de 2026	Criterio y resultado
Específico y medible	Evaluar detección binaria de noticias negativas con recall ≥0.90, precisión ≥0.60 y AUC ≥0.90.
Alcance realizable	Comparar dos algoritmos y dos baselines, fijar umbral sólo en desarrollo y registrar parámetros, métricas y artefactos.
Relevancia	Reducir omisiones con una carga de revisión asumible. Costo didáctico: 5 por falso negativo y 1 por falso positivo.
Evaluación de la meta	SVM: recall 0.836, precisión 0.671, AUC 0.955. Meta conjunta no alcanzada. No se rebaja después de ver los resultados.

Continuidad y alcance de los datos

Conservo Financial PhraseBank AllAgree y la partición de Actividad 5: 2,264 oraciones originales, cinco duplicados retirados, 2,259 registros limpios; 1,807 para desarrollo y 452 para test. La clase positiva ahora es negative; neutral y positive forman la clase no negativa. El cambio de tarea impide comparar directamente el F1 binario con el F1 macro de tres clases de la entrega anterior.

El test ya fue consultado en Actividad 5: esta evaluación es retrospectiva, no una validación externa independiente. Los 150 personajes con posiciones entre $5 y $20 millones MXN son ficticios y sirven para ilustrar perfiles y el experimento A/B. No aportan observaciones de rentabilidad ni etiquetas para entrenar el clasificador.

Protocolo de datos y validación

Financial PhraseBank contiene oraciones financieras en inglés anotadas por personas; AllAgree conserva acuerdo total. Su licencia CC BY-NC-SA 3.0 permite esta entrega académica, pero requiere revisar derechos antes de uso comercial. La selección de ejemplos con acuerdo total y el idioma limitan la transferencia a noticias mexicanas actuales.

Campo	Uso
id y texto_original	Rastro al registro original y texto sin reinterpretar.
texto	Normalización Unicode NFKC y espacios; única entrada predictora.
etiqueta y y	Etiqueta original; y=1 si negative, y=0 en otro caso.
split y n_caracteres	Partición histórica fija y longitud descriptiva; no son predictores.
cliente_id y perfil_riesgo	Sólo contexto simulado y estratos de asignación A/B.

La limpieza heredada elimina duplicados antes de separar; no hay textos vacíos ni etiquetas faltantes. No imputo ni traduzco. TF-IDF aprende vocabulario e IDF dentro de cada entrenamiento, con unigramas y bigramas, norma L2 y hasta 25,000 términos. No aplico escalado numérico adicional ni uso información del test en esa transformación.

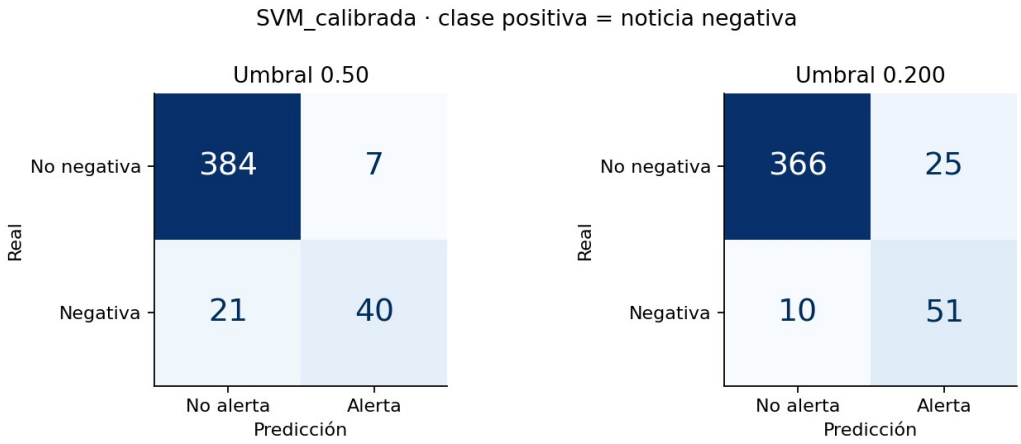
Comparo regresión logística (C=1, solver liblinear) y LinearSVC (C=1) con calibración sigmoide de tres folds. El pipeline TF-IDF completo se encuentra dentro de la calibración, evitando que su vocabulario vea el fold de calibración. Estos hiperparámetros se fijan para esta actividad; no presento una nueva búsqueda exhaustiva.

Uso cinco folds externos estratificados con semilla 20261022. En cada entrenamiento externo, tres folds internos generan probabilidades fuera de muestra para elegir umbral; después evalúo en su fold externo. La rejilla va de 0.05 a 0.95, en pasos de 0.025. Si no existe umbral que cumpla recall y precisión, elijo el menor costo 5FN+FP y marco la inviabilidad. El modelo se selecciona por costo medio externo; el umbral final se fija con cinco folds de desarrollo y se aplica al test histórico.

La selección entre dos modelos sobre esos mismos folds puede introducir optimismo; los folds no son muestras independientes. El bootstrap del test cuantifica incertidumbre condicional al corpus y al modelo ya ajustado, no deriva temporal ni incertidumbre completa de entrenamiento. Hace falta una evaluación prospectiva con noticias en español, separación temporal y agrupación por emisor o evento.

Cada ejecución registra hash de datos y código, semilla, parámetros, métricas y artefactos en MLflow. El repositorio conserva IDs de corrida, predicciones y folds. Se incluyen originales, licencia, versión limpia y manifiesto; el historial documenta el cambio de solver después de advertencias numéricas exploratorias.

Matriz de confusión y métricas



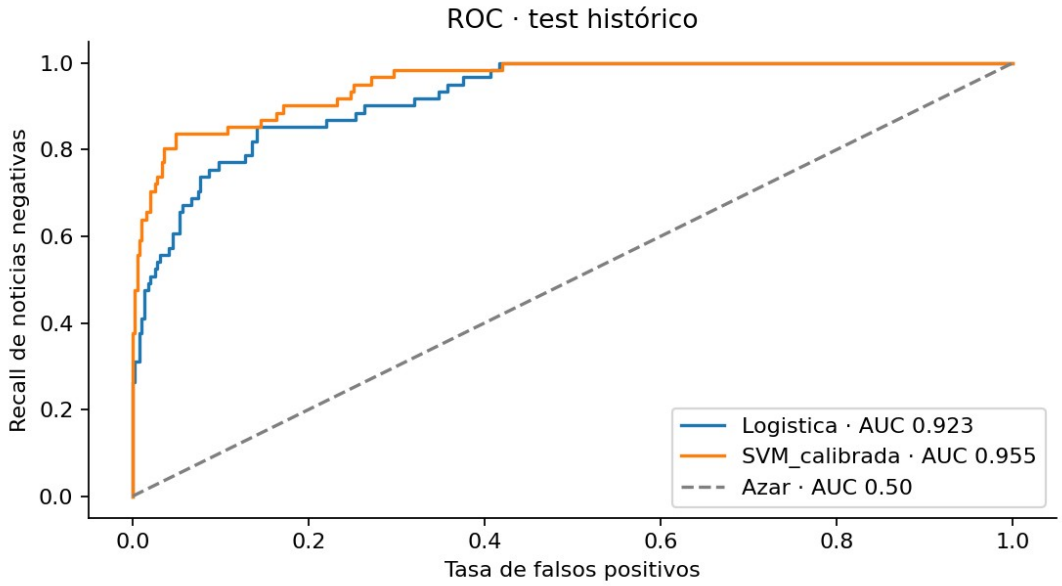
En el umbral elegido: verdaderos positivos (TP)=51, falsos negativos (FN)=10, falsos positivos (FP)=25 y verdaderos negativos (TN)=366. Un falso negativo deja una noticia adversa sin priorizar; un falso positivo consume revisión del banquero. Ninguno equivale automáticamente a una ganancia o pérdida financiera.

Métrica	Cálculo para SVM con umbral 0.20	Interpretación
Exactitud	(51+366)/452 = 0.9226	Proporción total correcta; la clase mayoritaria puede inflarla.
Precisión	51/(51+25) = 0.6711	Cerca de dos de cada tres alertas son negativas.
Recall	51/(51+10) = 0.8361	Detecta 83.6 % de las noticias negativas.
F1	2×51/(2×51+25+10) = 0.7445	Equilibra precisión y recall; no refleja por sí solo costos.

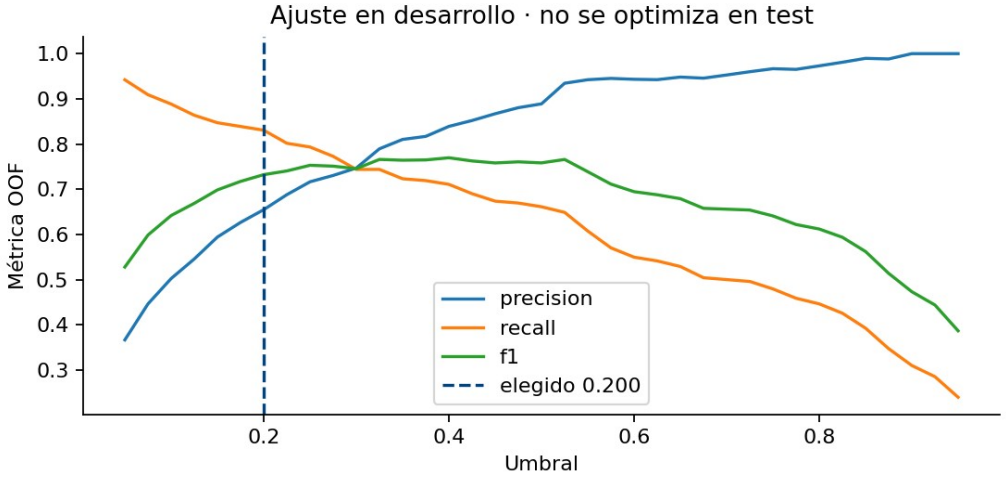
El baseline mayoritario logra 86.5 % de exactitud pero recall y F1 iguales a cero. Revisar todo logra recall de 100 %, precisión de 13.5 % y F1 de 23.8 %. Ambas referencias muestran por qué la exactitud aislada no basta: necesito recuperar señales útiles sin revisar todas las noticias.

Al bajar de 0.50 a 0.20, las omisiones pasan de 21 a 10, pero las falsas alertas suben de 7 a 25. La carga crece de 47 a 76 revisiones entre 452 noticias. El costo ponderado disminuye de 24.78 a 16.59 unidades por cada 100 noticias. Es una preferencia operativa explícita, no una estimación de pesos perdidos o ahorrados.

Umbral y capacidad de discriminación



La ROC recorre sensibilidad frente a tasa de falsos positivos. SVM obtiene AUC 0.9548 frente a 0.9229 de logística y 0.50 del baseline. Interpreto AUC como capacidad de ordenar una noticia negativa por encima de una no negativa; no representa 95.5 % de probabilidad de acertar, calibración perfecta ni rendimiento financiero futuro. Con prevalencia negativa de 13.5 %, también reporto precisión promedio de 0.8468 para SVM.



El umbral 0.20 se eligió en desarrollo; ninguno cumple simultáneamente las restricciones allí fijadas. La gráfica usa predicciones fuera de muestra de desarrollo. El explorador de Streamlit sobre test es didáctico: no debe utilizarse para retocar la decisión publicada. Cambiar el umbral altera los errores, pero no la ROC ni el AUC del mismo conjunto de puntuaciones.

Generalización y comparación estadística

Modelo y política	Accuracy	Precisión	Recall	F1	AUC
Logística 0.125	0.8053	0.3969	0.8525	0.5417	0.9229
SVM 0.50	0.9381	0.8511	0.6557	0.7407	0.9548
SVM 0.20	0.9226	0.6711	0.8361	0.7445	0.9548
Mayoría	0.8650	0	0	0	0.50
Revisar todo	0.1350	0.1350	1	0.2378	0.50

Cinco folds externos	Recall	F1	AUC	Costo por 100
Logistica	0.8066 ± 0.1064	0.5731 ± 0.0428	0.9128 ± 0.0347	26.3905 ± 6.2561
SVM_calibrada	0.8268 ± 0.0580	0.7242 ± 0.0585	0.9431 ± 0.0313	17.8156 ± 4.5212

Las dispersiones son desviaciones estándar entre folds, no intervalos de confianza. SVM obtiene el menor costo medio y es mi candidata. Los hiperparámetros fijos y la anidación del umbral ayudan a controlar fuga de información; el tamaño del corpus y la selección entre modelos siguen siendo limitaciones.

Con 2,000 remuestreos estratificados pareados del test, el IC percentil 95 % del AUC de SVM es [0.9284, 0.9761] y del F1 [0.6715, 0.8120]. El aumento de recall respecto al umbral 0.50 es de 18.03 puntos, con IC [8.20, 27.87] puntos. Estos intervalos condicionan al test disponible y no equivalen a una prueba externa.

McNemar exacto compara aciertos pareados entre ambos umbrales: 18 casos correctos sólo con 0.50 y 11 sólo con 0.20; p=0.2649. No rechazo igualdad de exactitud al 5 %. Esto no contradice el incremento de recall: son criterios diferentes, y el ajuste busca reducir omisiones ponderadas, no maximizar exactitud. No aplico una prueba t ingenua a cinco folds correlacionados ni declaro superioridad estadística de AUC entre modelos sin una prueba específica.

Seguimiento de experimentos

MLflow permite inspeccionar parámetros, métricas y artefactos de las dos corridas definitivas y la comparación con A/B. Las capturas del panel y el paquete portable de evidencia acompañan esta entrega. Los modelos se registran como archivos de artefacto; no se afirma que exista un servicio productivo ni un Model Registry con aprobaciones operativas.

Prueba A B e impacto en el negocio

Implementé una simulación aleatoria estratificada por perfil: 75 personajes en A (revisión manual) y 75 en B (asistida), una revisión por cliente. El indicador primario es revisión completa en 48 horas. Las probabilidades 0.72 y 0.85 son supuestos generadores, no estimaciones observadas. El resultado reproducible es 48/75 frente a 59/75: diferencia de 14.67 puntos porcentuales.

Fisher exacto bilateral arroja p=0.0703; con α=0.05 no rechazo H0: pA=pB. Un intervalo aproximado conservador de diferencia, formado con Wilson y corrección Bonferroni, es [−8.73, 36.23] puntos. Incluso una simulación significativa no probaría causalidad real: aquí sólo demuestro el procedimiento. CV evalúa generalización predictiva; un A/B real evaluaría efecto del flujo de trabajo sobre personas y procesos.

Para un piloto futuro fijaría cuatro semanas, asignación previa y análisis por intención de tratar; una revisión faltante cuenta como no completada. “Completa” exige fuente contrastada, perfil y horizonte revisados, costos documentados y visto bueno humano. Congelaría indicador, hipótesis y muestra antes de observar resultados, sin detener por significancia. El cálculo normal aproximado para 13 puntos de diferencia, potencia 80 % y α=0.05 requiere 156 por brazo, 174 con 10 % de pérdidas. No basta la cartera didáctica de 150; si se asigna por banquero, debe recalcularse por correlación y contaminación.

Como supuesto del caso, cobrar 1 % por venta y 1 % por compra implica 2 % sobre el nocional migrado. Con una mejora bruta anual de 3 puntos y sólo 35 % de cartera migrada, el aporte bruto sobre cartera es 1.05 puntos, frente a 0.70 puntos de corretaje sobre cartera: no se deben comparar bases diferentes. Sobre la parte migrada, 3 puntos sólo superan el costo de 2 puntos después de ocho meses bajo un supuesto lineal sin otros gastos. El clasificador no acredita esa mejora.

Consulté el índice público de BBVA México: 61 fichas DICI y 693 registros de comisiones por serie. La extracción automatizada conserva fuente y fecha; requiere validar vigencia, periodicidad y serie. Los gastos del fondo no son ingreso neto íntegro del banco. Si un rendimiento ya descuenta esos gastos, restarlos otra vez duplicaría el costo. Las señales nunca deben promover rotación sólo para generar corretaje.

Conclusión y siguientes controles

Mantengo SVM 0.20 como candidata académica, con supervisión humana y meta pendiente. Antes de un piloto necesito corpus mexicano con licencia apta, separación temporal por evento, calibración y sensibilidad por segmento, revisión de costos y capacidad, monitoreo de deriva y un mecanismo de reversión. Esta deuda técnica queda visible en el tablero; no se oculta detrás de una métrica alta.

Fuentes: temas 13 y 14 y rúbrica Actividad 6 proporcionados; Financial PhraseBank (Malo et al.), revisión HF 8d3fe0c; scikit-learn, documentación de ajuste de umbral y CalibratedClassifierCV; SciPy, fisher_exact y binomtest; MLflow Tracking; normativa de fondos BBVA México. Las URLs completas y evidencias están en el README del repositorio.